

Mon Projet Data Science

Projet Fil Rouge Data Science - Sujet Libre

2026-06-01

Table of contents

1	Introduction et Contexte Métier	2
1.1	Contexte du Projet	2
1.2	Objectif Analytique	3
2	Acquisition et Préparation des Données (Data Wrangling)	3
2.1	Chapitre 1 : Acquisition Multi-Sources	3
3	 Étape 1 : Acquisition des Données & Multi-Sources (Squelette Étudiant)	3
3.0.a	1. Initialisation de l'environnement	4
3.0.b	2. Chargement de la source de données principale	4
3.0.c	3. Intégration de données secondaires (Multi-Sources)	4
3.0.d	4. Fusion des sources (Optionnel)	4
3.0.e	5. Consignation des données d'entrée brutes	4
3.1	Chapitre 2 : Nettoyage et Préparation (Wrangling)	4
4	 Étape 2 : Préparation & Nettoyage de Données (Data Wrangling) (Squelette Étudiant) ...	4
4.0.a	1. Initialisation et imports	4
4.0.b	2. Chargement du dataset brut et Audit Initial	4
4.0.c	3. Uniformisation des Formats de Dates	4
4.0.d	4. Identification et Filtrage des Valeurs Aberrantes (Outliers)	4
4.0.e	5. Imputation des valeurs manquantes	4
4.0.f	6. Sauvegarde des données propres	5
5	Visualisation Multidimensionnelle (Insights)	5
5.1	Chapitre 3 : Travaux Pratiques d'Exploration Visuelle	5
6	 Étape 4 : Visualisation Multidimensionnelle (Squelette Étudiant)	5
6.0.a	1. Préparation de l'environnement	5
6.0.b	2. Chargement du dataset enrichi	5
6.0.c	3. Tracés et analyses graphiques	5
7	Analyse Exploratoire des Données (EDA)	5
7.1	Chapitre 4 : Travaux Pratiques d'Exploration (EDA)	6
8	 Étape 3 : Analyse Exploratoire des Données (EDA) (Squelette Étudiant)	6
8.0.a	1. Préparation de l'environnement	6
8.0.b	2. Chargement des données nettoyées	6
8.0.c	3. Statistiques Descriptives	6

8.0.d	4. Ingénierie de variables (Feature Engineering)	6
8.0.e	5. Analyse des Corrélations	6
9	Modélisation et Apprentissage	6
9.1	Chapitre 5 : Travaux Pratiques de Modélisation (ML & DL)	7
10	 Étape 5 : Modélisation (Machine Learning & Deep Learning) (Squelette Étudiant)	7
10.0.a	1. Préparation de l'environnement	7
10.0.b	2. Modélisation Tabulaire (Machine Learning)	7
10.0.c	3. Modélisation Vision / Deep Learning (CNN & TensorFlow)	7
11	Évaluation Métrique et Validation	7
11.1	Chapitre 6 : Travaux Pratiques d'Évaluation & Robustesse	7
12	 Étape 6 : Évaluation Métrique & Robustesse	7
13	Data Storytelling et Communication	7
13.1	Chapitre 7 : Travaux Pratiques de Storytelling	7
14	 Étape 7 : Data Storytelling & Communication	7
14.1	Insights clés	7
14.2	Présentation des Résultats (Livrables Interactifs)	8
14.2.a	 Diaporama de Soutenance (RevealJS)	8
14.2.b	 Exemple de Dashboard Dynamique (OJS / Plotly)	8
15	Utilisation de l'Intelligence Artificielle	9
15.1	Cartographie de l'utilisation de l'IA	9
15.2	Principes de Rigueur et Responsabilité	9
	Bibliographie	10
	Bibliography	10

1 Introduction et Contexte Métier

À rédiger par les étudiants : Présentez ici le contexte global de votre projet, la problématique métier que vous cherchez à résoudre, les questions scientifiques soulevées et les opportunités d'aide à la décision sur la base de vos données.

1.1 Contexte du Projet

À rédiger par les étudiants — Pistes de réflexion :

- *Quels sont les objectifs globaux et le domaine d'étude de votre projet ?*
- *En quoi ce sujet de recherche est-il pertinent et stratégique ?*
- *Pourquoi l'analyse quantitative de ce jeu de données est-elle indispensable pour répondre à votre problématique ?*

[Ce projet s'inscrit dans une problématique de Data Science appliquée au marché immobilier, un domaine où l'analyse de données joue un rôle clé dans la prise de décision des particuliers, agences et investisseurs.

L'objectif général est de comprendre et prédire les prix des logements à partir de plusieurs sources de données : caractéristiques tabulaires (surface, localisation, nombre de pièces, etc.), données contextuelles issues de plateformes immobilières, et données visuelles (images de logements).

Dans un contexte de marché immobilier fortement hétérogène, les prix peuvent varier de manière importante en fonction de critères complexes et non linéaires. L'analyse quantitative permet donc d'objectiver les facteurs influençant les prix, de détecter des patterns cachés dans les données, et de construire des modèles prédictifs fiables.]

1.2 Objectif Analytique

À rédiger par les étudiants — Pistes de réflexion :

- *Quelles sont les variables cibles principales et la tâche globale de modélisation (classification, régression, clustering, etc.) ?*
- *Comment le couplage de données multi-sources et l'intégration de différents types de données (tabulaires, images, signaux, etc.) enrichissent-ils l'analyse ?*
- *Quels sont les livrables analytiques attendus pour répondre à votre problématique et guider les prises de décisions ?*

[L'objectif principal du projet est de construire un modèle prédictif de régression capable d'estimer le prix d'un bien immobilier. Plus précisément, nous cherchons à prédire la variable cible SalePrice, analyser les variables explicatives (surface, localisation, équipements) et intégrer une dimension Deep Learning (CNN) sur des images de logements afin d'enrichir les prédictions.

Le projet suit une approche multimodale, combinant des données tabulaires structurées, des données non structurées (images), et des modèles d'apprentissage automatique avancés.

Les livrables attendus sont un pipeline complet de Data Science, un modèle prédictif performant (RandomForest $R^2=0.73$), un CNN TensorFlow (accuracy 52.5%) et un dashboard interactif d'aide à la décision.]

2 Acquisition et Préparation des Données (Data Wrangling)

Le succès de tout projet de Data Science repose sur la qualité de la préparation des données [1]. Cette section documente l'audit de qualité et les étapes de nettoyage appliquées à vos jeux de données bruts.

2.1 Chapitre 1 : Acquisition Multi-Sources

3 📁 Étape 1 : Acquisition des Données & Multi-Sources (Squelette Étudiant)

Cette étape correspond au premier chapitre du pipeline de Data Science. L'objectif est d'identifier, d'importer et de consolider vos jeux de données bruts issus de différentes sources (fichiers CSV locaux, requêtes API, bases de données, etc.).

3.0.a 1. Initialisation de l'environnement

3.0.b 2. Chargement de la source de données principale

À COMPLÉTER PAR L'ÉTUDIANT : Chargez votre jeu de données principal (par exemple un fichier CSV stocké dans `data/raw/`).

3.0.c 3. Intégration de données secondaires (Multi-Sources)

À COMPLÉTER PAR L'ÉTUDIANT : Mettez en place la récupération de vos données complémentaires (par exemple, appels d'API fictifs ou réels, données météo, géographiques, ou financiers complémentaires).

3.0.d 4. Fusion des sources (Optionnel)

À COMPLÉTER PAR L'ÉTUDIANT : Associez vos différentes sources de données en utilisant des jointures (`pd.merge`) pertinentes.

3.0.e 5. Consignation des données d'entrée brutes

Sauvegardez l'état brut de vos données d'entrée pour la suite du pipeline.

3.1 Chapitre 2 : Nettoyage et Préparation (Wrangling)

4 🧹 Étape 2 : Préparation & Nettoyage de Données (Data Wrangling) (Squelette Étudiant)

Cette étape correspond au deuxième chapitre du projet. L'objectif est d'effectuer un audit de qualité de vos données brutes, puis de mettre en œuvre un nettoyage rigoureux à l'aide de votre package personnalisé `src.data_clean`.

4.0.a 1. Initialisation et imports

4.0.b 2. Chargement du dataset brut et Audit Initial

À COMPLÉTER PAR L'ÉTUDIANT : Chargez les données brutes et inspectez la qualité du dataset (taux de valeurs manquantes, présence de doublons, types erronés).

4.0.c 3. Uniformisation des Formats de Dates

À COMPLÉTER PAR L'ÉTUDIANT : Uniformisez la colonne temporelle pour la convertir dans un type datetime standardisé via votre module `src.data_clean`.

4.0.d 4. Identification et Filtrage des Valeurs Aberrantes (Outliers)

À COMPLÉTER PAR L'ÉTUDIANT : Identifiez les anomalies physiques et utilisez votre fonction `dc.handle_outliers` pour transformer ces valeurs aberrantes en NaNs.

4.0.e 5. Imputation des valeurs manquantes

À COMPLÉTER PAR L'ÉTUDIANT : Appliquez des stratégies d'imputation adaptées (interpolation temporelle, médiane, etc.) sur les valeurs manquantes générées ou initiales.

4.0.f 6. Sauvegarde des données propres

Enregistrez vos données de base nettoyées dans le répertoire `data/processed/`.

5 Visualisation Multidimensionnelle (Insights)

Nous présentons ici les résultats visuels clés permettant de dégager des insights exploitables pour les décideurs, en s'appuyant sur notre module `src/utils_viz.py`.

5.1 Chapitre 3 : Travaux Pratiques d'Exploration Visuelle

6 Étape 4 : Visualisation Multidimensionnelle (Squelette Étudiant)

Cette étape correspond au quatrième chapitre du cours. L'objectif est de concevoir des représentations visuelles premium pour identifier des tendances et insights clés à l'aide de votre package personnalisé de tracé `src.utils_viz`.

6.0.a 1. Préparation de l'environnement

6.0.b 2. Chargement du dataset enrichi

6.0.c 3. Tracés et analyses graphiques

6.0.c.a A. Évolution des tendances dans le temps

À COMPLÉTER PAR L'ÉTUDIANT : Tracez les tendances globales à l'aide de la fonction `uv.plot_generic_trends`.

6.0.c.b B. Carte de chaleur des corrélations

À COMPLÉTER PAR L'ÉTUDIANT : Visualisez graphiquement les corrélations de Pearson à l'aide de `uv.plot_correlation_matrix`.

6.0.c.c C. Nuage de points bivarié

À COMPLÉTER PAR L'ÉTUDIANT : Générez une analyse graphique bivariée en utilisant `uv.plot_bivariate_scatter`.

7 Analyse Exploratoire des Données (EDA)

Dans cette section, nous analysons les relations statistiques fondamentales qui régissent votre domaine d'étude au sein du jeu de données.

7.1 Chapitre 4 : Travaux Pratiques d'Exploration (EDA)

8 Étape 3 : Analyse Exploratoire des Données (EDA) (Squelette Étudiant)

Cette étape correspond au troisième chapitre du cours. L'objectif est d'explorer et de résumer les propriétés statistiques fondamentales de vos données et de réaliser du **Feature Engineering** pour enrichir vos modèles.

8.0.a 1. Préparation de l'environnement

8.0.b 2. Chargement des données nettoyées

8.0.c 3. Statistiques Descriptives

À COMPLÉTER PAR L'ÉTUDIANT : Générez les résumés statistiques globaux et par groupes/catégories de votre jeu de données.

8.0.d 4. Ingénierie de variables (Feature Engineering)

À COMPLÉTER PAR L'ÉTUDIANT : Appliquez la fonction `feature_engineering` de `src.data_clean` pour extraire des indicateurs temporels de base, et ajoutez d'autres variables dérivées complexes adaptées à votre problématique.

8.0.e 5. Analyse des Corrélations

À COMPLÉTER PAR L'ÉTUDIANT : Analysez la matrice des corrélations des caractéristiques numériques à l'aide de Pandas.

9 Modélisation et Apprentissage

Le pipeline complet intègre à la fois la branche analytique tabulaire (Machine Learning) et la branche d'analyse visuelle ou de signaux complexes (Deep Learning CNN) :

```
graph TD
    A[Données Brutes Multi-Sources CSV/API] -->|Formatage & Alignement| B(data_clean.clean_dates)
    C[Données Externes Complémentaires] -->|Imputation & Interpolation| D(data_clean.impute_missing_values)
    B & D -->|Gestion Outliers| E[Jeu de données Propre & Fusionné]
    E -->|Extraction Temporelle/Caractéristiques| F[Feature Engineering]
    F -->|Splits Temporels ou Stratifiés| G[Modèle Machine Learning Tabulaire]
    H[Flux Multimédias Réels Images/Signaux] -->|Prétraitement d'images/signaux| I[Réseau Convolutif CNN TensorFlow]
    G -->|Prédictions de la Problématique Métier| J[Livrables & Aide à la Décision]
    I -->|Détection de Motifs Complexes| J
```

```
style E fill:#e0f2fe,stroke:#0284c7,stroke-width:2px
style J fill:#f0fdf4,stroke:#16a34a,stroke-width:2px
style G fill:#fef3c7,stroke:#d97706,stroke-width:2px
style I fill:#fef3c7,stroke:#d97706,stroke-width:2px
```

9.1 Chapitre 5 : Travaux Pratiques de Modélisation (ML & DL)

10 🧠 Étape 5 : Modélisation (Machine Learning & Deep Learning) (Squelette Étudiant)

Cette étape correspond au cinquième chapitre du cours. L'objectif est d'implémenter d'une part un modèle de Machine Learning tabulaire (ex: RandomForest) et d'autre part un réseau de neurones convolutif (CNN) sous TensorFlow pour traiter des images ou signaux complexes.

10.0.a 1. Préparation de l'environnement

10.0.b 2. Modélisation Tabulaire (Machine Learning)

À COMPLÉTER PAR L'ÉTUDIANT : Entraînez un modèle d'apprentissage supervisé (ex: forêt aléatoire) sur les caractéristiques extraites de votre jeu de données.

10.0.c 3. Modélisation Vision / Deep Learning (CNN & TensorFlow)

À COMPLÉTER PAR L'ÉTUDIANT : Pour des motifs complexes (images/signaux), mettez en place un réseau convolutif (Conv2D, Pooling, Dense) pour classifier ou enrichir vos prédictions.

11 Évaluation Métrique et Validation

11.1 Chapitre 6 : Travaux Pratiques d'Évaluation & Robustesse

12 🛠️ Étape 6 : Évaluation Métrique & Robustesse

Protocole d'évaluation rigoureux pour valider la qualité du modèle RandomForest sur le dataset House Prices.

13 Data Storytelling et Communication

13.1 Chapitre 7 : Travaux Pratiques de Storytelling

14 📢 Étape 7 : Data Storytelling & Communication

Synthèse des résultats et restitution interactive pour les décideurs.

14.1 Insights clés

1. La qualité de construction (OverallQual) est le facteur n1 - 57% importance

2. La surface habitable (GrLivArea) est le facteur n2 - 19% importance
3. Les biens de luxe sont identifiables visuellement - CNN 67% precision sur classe Luxe
4. Prix median : 163 000\$ - Prix moyen : 180 921\$ - ecart du aux outliers

14.2 Présentation des Résultats (Livrables Interactifs)

14.2.a Diaporama de Soutenance (RevealJS)

Ci-dessous est intégré le squelette de votre diaporama de soutenance RevealJS. Utilisez-le pour présenter votre démarche aux décideurs de façon professionnelle.

14.2.b Exemple de Dashboard Dynamique (OJS / Plotly)

Voici un exemple minimal de code montrant comment intégrer un graphique dynamique contrôlé par un composant d'interface utilisateur en Observable JS (OJS).

```
//| echo: true
// Boutons de sélection interactifs OJS
viewof selectedCategory = Inputs.select(["Toutes", "A", "B", "C"], {value:
"Toutes", label: "Filtrer par Catégorie :"})
```

```
//| echo: false
// Données simulées réactives
data = [
  {timestamp: "2026-05-18T00:00:00Z", value: 10.5, category: "A"},
  {timestamp: "2026-05-18T02:00:00Z", value: 12.1, category: "A"},
  {timestamp: "2026-05-18T04:00:00Z", value: 14.7, category: "A"},
  {timestamp: "2026-05-18T05:00:00Z", value: 15.2, category: "A"},
  {timestamp: "2026-05-18T06:00:00Z", value: 16.0, category: "B"},
  {timestamp: "2026-05-18T07:00:00Z", value: 18.3, category: "B"},
  {timestamp: "2026-05-18T09:00:00Z", value: 21.5, category: "B"},
  {timestamp: "2026-05-18T10:00:00Z", value: 22.0, category: "B"},
  {timestamp: "2026-05-18T12:00:00Z", value: 25.4, category: "C"},
  {timestamp: "2026-05-18T13:00:00Z", value: 26.1, category: "C"},
  {timestamp: "2026-05-18T15:00:00Z", value: 28.9, category: "C"},
  {timestamp: "2026-05-18T16:00:00Z", value: 30.2, category: "C"}
]

// Filtrage réactif de la donnée
filteredData = selectedCategory === "Toutes"
  ? data
  : data.filter(d => d.category === selectedCategory)

// Tracé interactif avec la librairie Plotly
Plotly.newPlot('dynamic-chart', [{
```

```

x: filteredData.map(d => d.timestamp),
y: filteredData.map(d => d.value),
type: 'scatter',
mode: 'lines+markers',
marker: {color: '#1A73E8', size: 8},
line: {shape: 'spline', color: '#1A73E8', width: 3}
}], {
  title: 'Évolution Dynamique des Valeurs (Filtrée)',
  margin: {t: 50, b: 50, l: 50, r: 50},
  paper_bgcolor: 'rgba(0,0,0,0)',
  plot_bgcolor: 'rgba(0,0,0,0)',
  xaxis: {gridcolor: '#E5E7EB'},
  yaxis: {gridcolor: '#E5E7EB'}
})

```

15 Utilisation de l'Intelligence Artificielle

Dans une démarche de transparence scientifique et académique, cette section détaille la manière dont les outils d'Intelligence Artificielle (IA) générative ont été intégrés tout au long de la réalisation de ce projet.

15.1 Cartographie de l'utilisation de l'IA

Outil d'IA	Cas d'usage (Pourquoi ?)	Méthode d'utilisation (Comment ?)	Rôle et Validation Humaine
Claude (Anthropic)	Assistance au débogage du code et structuration du rapport	Outil de pair-programming utilisé pour débloquer des erreurs techniques et structurer les explications	Tous les choix techniques, algorithmes et analyses ont été décidés et validés par l'équipe ; le code a systématiquement été testé et compris avant intégration

15.2 Principes de Rigueur et Responsabilité

1. **Responsabilité intellectuelle** : L'équipe assume l'entière responsabilité des analyses, des choix de modèles et des conclusions présentées dans ce rapport.
2. **Lutte contre les hallucinations** : Chaque suggestion technique a fait l'objet d'une validation empirique.
3. **Protection des données** : Aucun jeu de données confidentiel ou sensible n'a été soumis à des modèles tiers en ligne.

Bibliographie

Bibliography

- [1] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*. O'Reilly Media, 2020.